上海大学 SHANGHAI UNIVERSITY

论文研读汇报

自蒸馏微调 · TRACE 回合级信用分配 · RLVR 更新方向

汇报人：聂冬亮

2026 年 8 月 20 日

目录

1. 汇报一：自蒸馏微调：从示范中实现持续学习
   - 背景与动机
   - 方法：SDFT
   - 理论：隐式 IRL
   - 实验

持续学习：下一代基础模型的根本挑战

- 基础模型能力出众，但部署后保持静态——不更新参数，无法获取新技能、内化新知识
- 目标：像人类一样终生学习，随时间积累知识与技能
- 从示范中学习是主流路径，其中SFT 占据主导地位

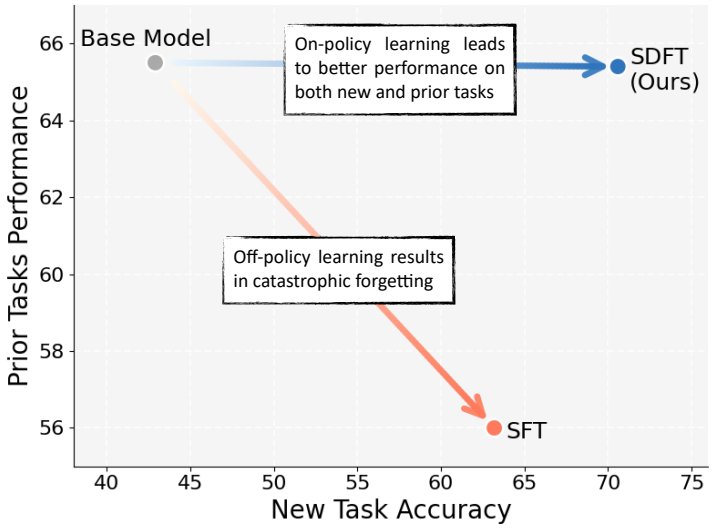
On Policy vs Off Policy

On Policy 学习（模型从自身当前策略生成的数据中学习）显著减轻灾难性遗忘，但多发生在 RL 语境下，需要显式奖励函数；而 SFT 在固定离线数据分布上训练，本质是Off Policy的。

核心问题

当只有专家示范可用时，如何获得 On Policy 学习的好处?

SFT 的不足

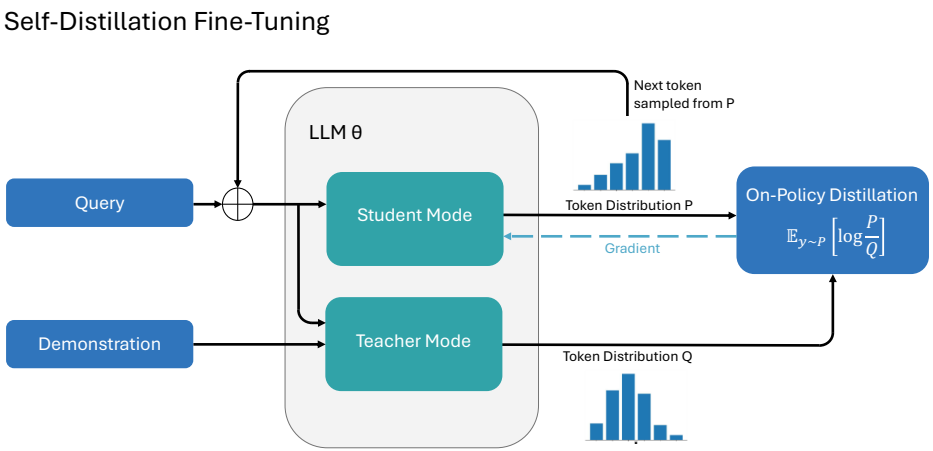


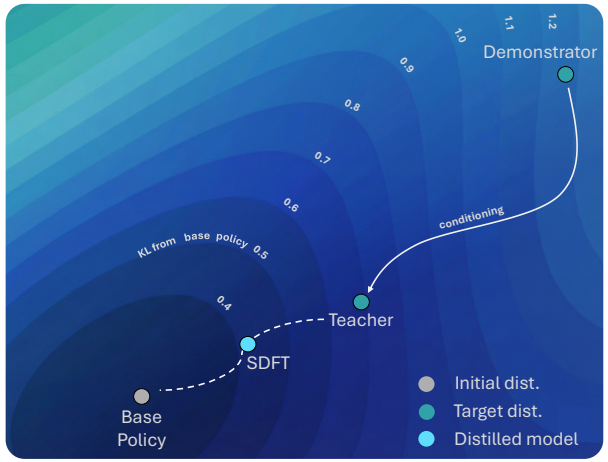
SFT 学习新任务后通用能力回退；

SDFT 持续进步且不回退。

- 累积误差：Off Policy 模仿只在专家诱导的轨迹上训练；推理时策略偏移到未见过状态，错误迅速累积 [RGB11]
- 灾难性遗忘：序列化 SFT 适配新任务/领域时，通用能力显著退化 [KPR+17]
- 原则上可用 逆强化学习（IRL）先学奖励再做 On Policy RL，但 IRL 依赖强结构假设（Boltzmann 策略、轨迹可分、偏好对），难以扩展

核心思想：一个模型，两个角色





- 教师：以专家示范为条件 $\pi(\cdot|x, c)$——利用模型的上下文学习（ICL)能力，无需参数更新即可调整行为
- 学生：仅以查询为条件 $\pi_\theta(\cdot|x)$
- 训练：在学生自身生成的轨迹上，将教师预测蒸馏到学生，最小化两者间的 KL 散度

教师提示模板

构造教师：以提示 + 示范同时为条件

```
<Question>
This is an example for a response to the question:
<Demonstration>
Now answer with a response of your own, including the thinking process:
```

- 该提示足以防止策略逐字输出示范，转而引发反映模型对示范意图理解的响应
- 示范是逐实例动态选择的，而非固定提示前缀——使教师能表达细粒度任务意图

训练目标与实现

- 对每个查询 x，从学生策略采样 $y \sim \pi_\theta(\cdot|x)$，最小化反向 KL 散度：

$$\mathcal{L}(\theta) = D_{\mathrm{KL}}\big(\pi_\theta(\cdot|x) \,\big\|\, \pi(\cdot|x,c)\big) = \mathbb{E}_{y\sim\pi_\theta(y|x)}\left[\log \frac{\pi_\theta(y|x)}{\pi(y|x,c)}\right]$$

- 借助自回归结构分解为词元级损失，视教师固定求梯度：

$$\nabla_\theta \mathcal{L} = \mathbb{E}_{y\sim\pi_\theta}\left[\sum_t \sum_{v\in\mathcal{V}} \pi_\theta(v|y_{<t},x) \log \frac{\pi_\theta(v|y_{<t},x)}{\pi(v|y_{<t},x,c)} \nabla_\theta \log \pi_\theta(v|y_{<t},x)\right]$$

- 实际实现要点（附消融）：教师采用学生参数的 EMA；实践中最优的是前向 KL + logit 级损失；训练时掩蔽前几个词元的损失以抑制伪迹

从信任域 RL 到隐式奖励

- 标准信任域正则化 RL：第 $k+1$ 步策略约束在接近当前策略处

$$\pi_{k+1} = \max_{\pi} \ \mathbb{E}_{y\sim\pi}[r(y,x)] - \beta\, D_{\mathrm{KL}}\big(\pi(\cdot|x) \,\|\, \pi_k(\cdot|x)\big)$$

- 最优策略闭式解（倾斜分布）：
  $\pi^*_{k+1}(y|x) \propto \pi_k(y|x)\exp\big(\frac{1}{\beta}r(y,x)\big)$
- 反推潜在奖励为两步策略散度之差

上下文假设——模型自身 ICL 能力提供最优策略的近似

$\pi^*_{k+1}(y|x) \approx \pi(y|x,c)$，即示范引发的行为偏移反映了专家的真实意图。

- 代入后得到隐式奖励：$r(y,x,c) = \log\pi(y|x,c) - \log\pi_k(y|x)$
- 自回归分解为词元级奖励：$r_t = \log\dfrac{\pi(y_t|y_{<t},x,c)}{\pi_k(y_t|y_{<t},x)}$

策略梯度等价性：蒸馏 $\Leftrightarrow$ IRL

- 对当前策略 π_k 施加策略梯度（等价于对该隐式奖励优化）：

$$\nabla_\theta J(\pi_k) = \mathbb{E}_{y\sim\pi_k}\left[\log \frac{\pi(y|x,c)}{\pi_k(y|x)}\ \nabla_\theta \log \pi_k(y|x)\right]$$

- 该期望上的梯度恰好等于反向 KL 散度 $D_{\mathrm{KL}}(\pi_k \,\|\, \pi(\cdot|x,c))$ 的梯度

结论

SDFT 可视为一种On Policy RL 算法：把学生的当前行为与其自身“更睿智”、具有示范感知的对应版本比较，来最大化推断出的奖励——无需显式奖励工程即可获得 On Policy RL 的好处。

策略梯度等价性：完整推导

$$
\begin{aligned}
\nabla_\theta J(\pi_k) &= -\mathbb{E}_{y\sim\pi_k}\left[\frac{\pi(y \mid x,c)}{\pi_k(y \mid x)}\,\nabla_\theta \log \pi_k(y \mid x)\right] \\
&= -\sum_y \pi_k(y \mid x)\,\frac{\pi(y \mid x,c)}{\pi_k(y \mid x)}\,\nabla_\theta \log \pi_k(y \mid x) \\
&= -\sum_y \pi(y \mid x,c)\,\nabla_\theta \log \pi_k(y \mid x) \\
&= -\mathbb{E}_{y\sim\pi(\cdot|x,c)}\left[\nabla_\theta \log \pi_k(y \mid x)\right] \\
&= -\nabla_\theta\,\mathbb{E}_{y\sim\pi(\cdot|x,c)}\left[\log \frac{\pi_k(y \mid x)}{\pi(y \mid x,c)}\right] \\
&= \nabla_\theta\, D_{\mathrm{KL}}\left(\pi(\cdot \mid x,c) \,\|\, \pi_k(\cdot \mid x)\right).
\end{aligned}
$$

等价性

$\nabla_\theta J(\pi_k) = \nabla_\theta D_{\mathrm{KL}}(\pi(\cdot \mid x,c) \,\|\, \pi_k(\cdot \mid x))$：对隐式奖励优化 $\Leftrightarrow$ 最小化教师-学生 KL。

验证 ICL 假设（两个必要条件）

条件 1：最优性

教师期望奖励 $\approx$ 最优策略：ToolAlpaca 上，无示范基础模型仅 42%，示范条件化教师达 100%；人工检查 50 条推理轨迹，思维链均有效且有语义依据。

条件 2：最小偏移

教师应在 KL 意义上与 π_k 保持接近：SFT 到基础偏差 1.26 nats，教师仅 0.68 nats（几乎一半）——既高质量又锚定于基础分布。

知识获取：分布内外均大幅领先

方法	准确率（严格）	准确率（宽松）	OOD 准确率
基础模型	0	0	0
Oracle RAG	91	100	100
CPT	9	37	7
SFT	80	95	80
SDFT（本文）	**89**	**100**	**98**

数据：2025 年自然灾害维基语料（≈200K 词元，训练截止后新事实）+ GPT-5 生成问答对（约 5× 源语料）；评估：分布内准确率 + OOD 准确率（“间接”问题，衡量知识是否真正内化）。主体实验：Qwen2.5-7B-Instruct。

- 严格准确率 $80\% \rightarrow 89\%$，几乎弥合与 oracle RAG 的差距
- OOD 上优势更明显（$80\% \rightarrow 98\%$）：SFT 教会模型复现答案，但未能把事实整合进知识库；SDFT 则实现真正的知识内化

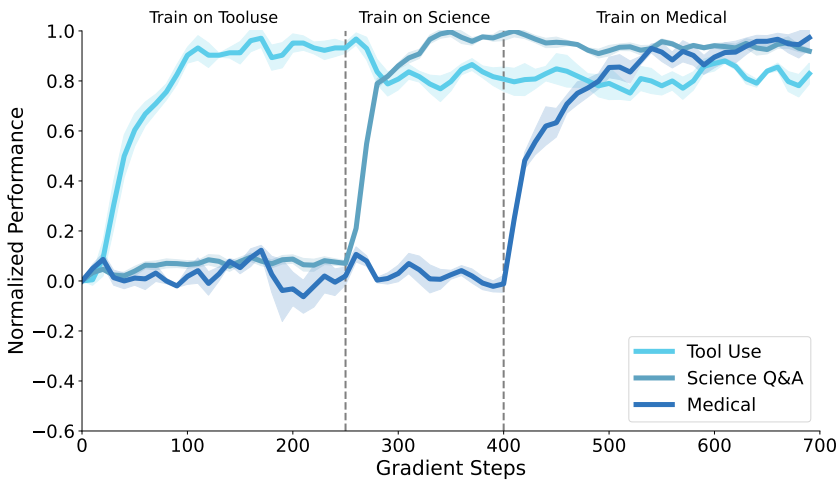
单任务微调：唯一同时提升新任务与保留旧能力的

任务	新任务准确率					既有能力平均				
	Base	SFT	+Re-inv	DFT	**SDFT**	Base	SFT	+Re-inv	DFT	**SDFT**
科学问答	32.1	66.2	66.0	54.8	**70.2**	65.5	53.4	60.2	60.2	**64.5**
工具使用	42.9	63.2	63.1	64.2	**70.6**	65.5	56.0	63.7	60.8	**65.4**
医学	30.1	35.5	35.6	36.2	**40.2**	65.5	60.2	62.6	64.0	**65.4**

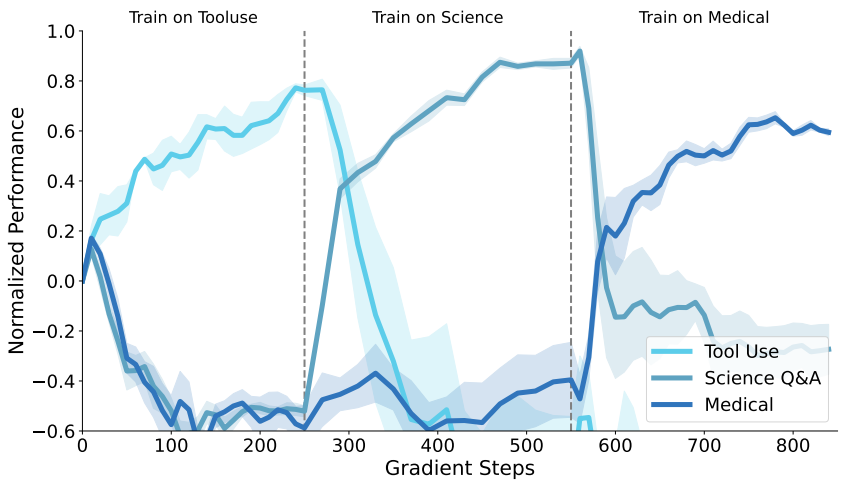
基线：SFT、DFT（重要性采样近似 On Policy）、SFT+Re-invocation；既有能力 = HellaSwag/TruthfulQA/MMLU/IFEval/Winogrande/HumanEval 平均。

- SDFT 是唯一能在不显著降低既有能力（Avg≈ 65，几乎与 Base 持平）的同时提升新任务性能的方法
- SFT 在所有基准上产生显著遗忘；Re-invocation 只能部分恢复；DFT 遗忘仍明显

多任务序列学习：技能随时间稳定累积



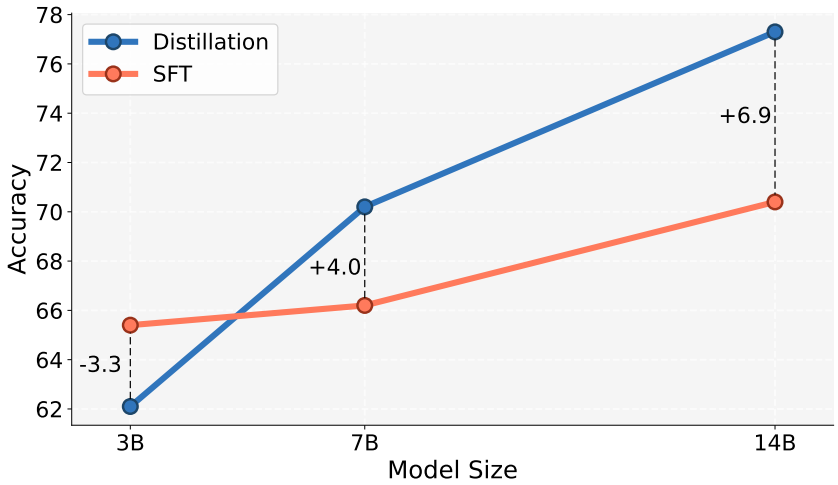
SDFT



SFT

- 单个模型依次在三种技能上训练（性能线性归一化：0=Base 准确率，1= 最高准确率）
- SDFT：每个新任务不断进步，同时保持先前任务性能 ⇒ 累积式学习
- SFT：一旦转向新任务，早期技能性能迅速退化 ⇒ 振荡而非累积

模型规模：收益随 ICL 能力增长



科学问答任务上 SDFT vs SFT 差距随规模扩大。

- 小规模（3B）ICL 太弱，教师信号不足，性能落后于 SFT
- 规模增大后收益持续增长：7B +4 个点，14B +7 个点
- 方法有效性紧密耦合于上下文推理能力，随更大模型 ICL 增强而更具优势

无推理数据的推理模型训练：避免推理坍缩

方法	准确率	平均词元数
Olmo-3-7B-Think	31.2	4612
+ SFT	23.5	3273
+ **SDFT**	**43.7**	4180

- 现实数据集常只有最终答案、无思维链标注；直接 SFT 会抑制模型已有的长链思考行为
- SFT 不仅损害性能（$31.2 \rightarrow 23.5$），且响应急剧缩短（≈1.4K 词元）——推理深度坍缩
- SDFT 向示范条件化教师学习（教师诱导出与推理一致的目标分布），保留推理风格的同时性能提升至 43.7%

讨论与局限

- 与 On Policy RL 互补：非替代品。SDFT 无需奖励；On Policy RL 需奖励信号。二者可自然结合——SDFT 可作为后续 RL 微调的更强初始策略
- 效率：每提示仅需一次 On Policy 生成（GRPO 等依赖分组采样），且提供词元级/logit 级的 dense credit assignment

局限与失败模式

- 计算成本：相比 SFT 约 2.5× FLOPs、4× 墙钟时间；但相对 Re-invoke 等多阶段流程总时长可能更短
- 学习伪迹：学生可能复现教师输出中的“根据文本……”等短语——训练时掩蔽前几个词元的损失可抑制，但本质是启发式修复
- 依赖 ICL 能力：小模型无法提供有意义的教师信号；难以实现激进行为改变（如非推理 → 推理模型）
- 理论与实践张力：理论等价性对应 reverse KL，最佳实践却是 forward KL / logit-level 蒸馏——未解释 forward KL 为何更优

目录

2 汇报二：TRACE：面向长时程智能体的 turn-level reward assignment
- 背景与动机
- 方法：TRACE
- 实验

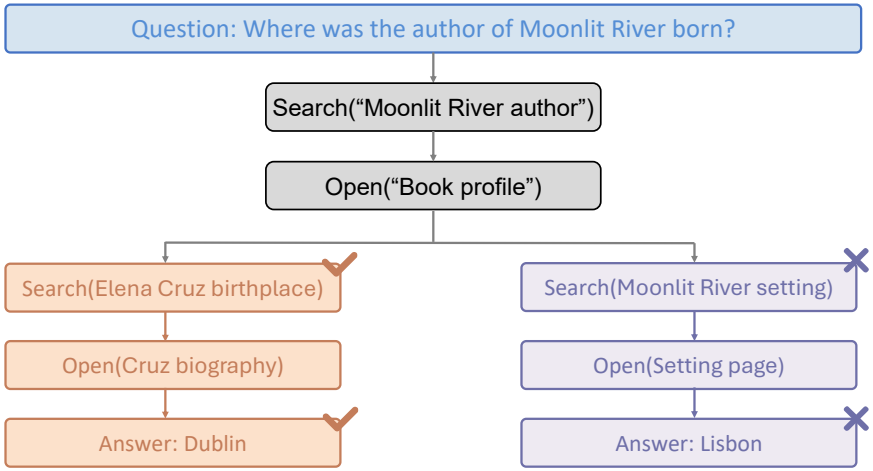
长时程智能体：从单回合推理到多轮工具交互

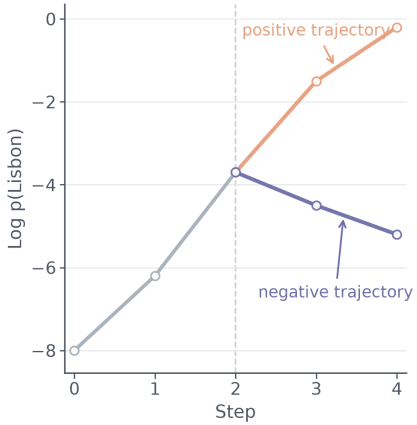
- Agent 解决复杂任务需要几十次甚至更多轮工具交互（网页导航、软件工程、通用计算机）[YZY+23, NHB+21]
- 能否把单轮推理上有效的 RLVR（如 GRPO）直接扩展？—— GRPO 只按最终结果算 reward、组内相对优势，单轮推理任务合理 [SWZ+24, DA+25]
- 但长时程轨迹有几十次工具调用，最终只有一个成败奖励——典型的奖励稀疏问题
- 只看结果无法回答：哪次搜索找到关键证据？哪些调用有用？哪些只是冗余带偏？

核心问题

仅用最终答案 + 冻结的 reference model（无需 turn-level 奖励 / Critic），自动判断哪些中间交互真正推动 Agent 接近答案，并转化为turn-level 稠密奖励。

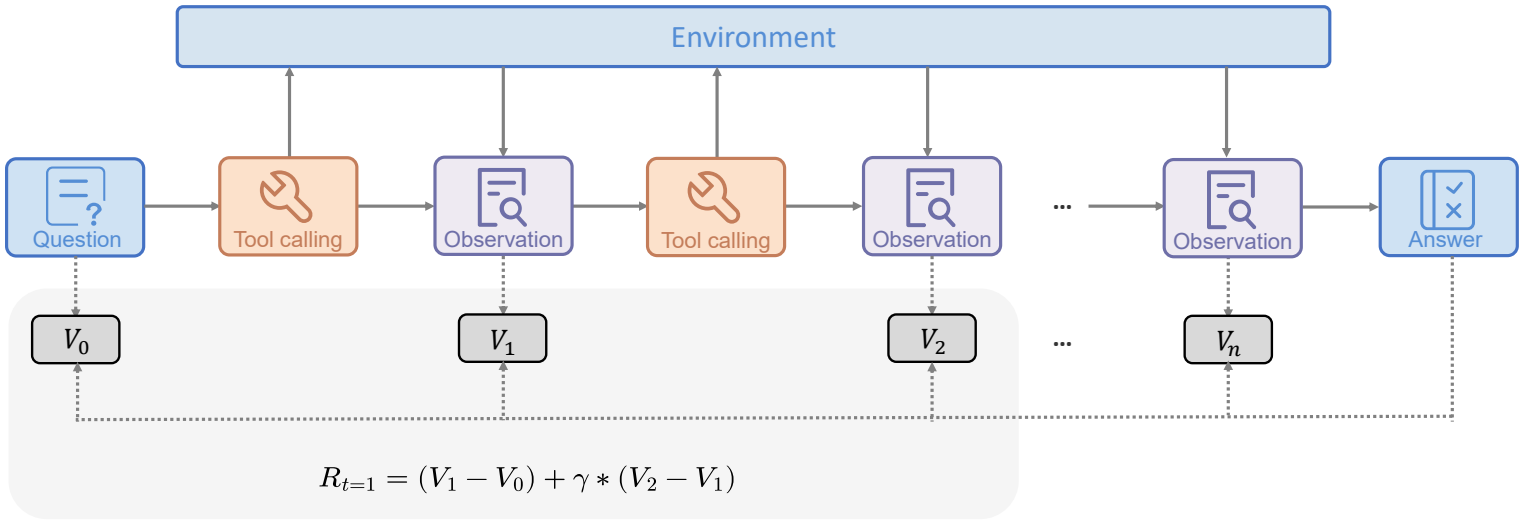
动机：credit assignment 缺陷





- 失败的轨迹可能以有用的搜索/打开动作开头；成功的轨迹也可能包含冗余搜索
- 类似 GRPO 的方法给所有回合分配相同的 trajectory-level 优势：低估有效探索、高估无关动作、增大梯度方差
- TRACE 并不替换 GRPO，而是在 GRPO 的优势函数之外，引入一个免 Critic 的的 turn-level 级的奖励信号，把最终奖励进一步落实到中间工具交互

TRACE 方法总览



- 轨迹按工具调用边界切分；冻结的 reference model（策略初始化的副本）为每条前缀打分
- 把前缀答案 log-probability 映射为log-ratio state value $V(S_k)$
- 用相邻价值的TD 变化作为 turn-level 奖励，并与标准 GRPO 组内相对优势 联合
- 组内相对优势仍是任务成功的最终裁决者；无需额外 critic 或过程标签训练

state value：从 reference-answer log-probability 到 log-ratio

- reference score：对前缀 S_k，冻结 reference model π_{ref} 的平均 reference-answer log-probability

$$\bar{\ell}_k = \frac{1}{|y^\star|} \sum_{t=1}^{|y^\star|} \log \pi_{\text{ref}}\big(y_t^\star \mid S_k, y_{<t}^\star\big) \le 0$$

  越大的 $\bar{\ell}_k$（负得越少）$\Rightarrow$ 前缀包含更多生成 $y^\star$ 的证据
- log-ratio value：设 $d_k = -\bar{\ell}_k + \varepsilon$，则

$$V(S_k) = \log \frac{d_0}{d_k} = \log \frac{-\bar{\ell}_0 + \varepsilon}{-\bar{\ell}_k + \varepsilon}, \qquad V(S_0) = 0$$

- 度量初始答案似然差距的相对闭合程度：$0.2 \to 0.1$ 消除了不确定性的一半，而 $5.1 \to 5.0$ 几乎没改变什么
- 冻结模型使探针在策略更新期间保持稳定，防止它变成另一个学到的奖励模型

为什么取 log：把乘性关系变成加性关系

- 过程 $d_0 \to d_1 \to d_2$：直接用 ratio 是乘性关系

$$\frac{d_0}{d_2} = \frac{d_0}{d_1} \times \frac{d_1}{d_2}$$

- 取 log 变为加性关系，各步可拆开相加

$$\log \frac{d_0}{d_2} = \log \frac{d_0}{d_1} + \log \frac{d_1}{d_2}$$

- 逐回合 credit $r_k \approx V(S_{k+1}) - V(S_k)$ 因此可直接相加，产生 telescoping

$$\sum_k \left[V(S_{k+1}) - V(S_k)\right] = V(S_T) - V(S_0)$$

- 总 credit 只依赖首尾两端——冗余中间回合无法夸大，正符合逐回合信用分配的需求

TD turn-level reward 与联合优化

- 单步 TD 信用（无中间奖励、$\gamma = 1$）：

$$\delta_k = V(S_{k+1}) - V(S_k) = \log \frac{d_k}{d_{k+1}}, \qquad k = 0, \ldots, T-1$$

- telescoping property：$\sum_{k=0}^{T-1} \delta_k = V(S_T) - V(S_0)$，只依赖两个端点——冗余的中间回合无法夸大总信用
- K-step backup：应对延迟证据（如 `search` 的候选链接在 `open` 后才暴露）

$$c_k^{(K)} = \frac{1}{Z} \sum_{u=k}^{h_k} \gamma_{\mathrm{td}}^{u-k}\, \delta_u, \qquad Z = \sum_{u=k}^{h_k} \gamma_{\mathrm{td}}^{u-k}$$

- 终端锚定 + 联合优化：

$$r_k^{\mathrm{turn}} = c_k^{(K)} + \mathbf{1}[h_k = T-1]\, \lambda_{\mathrm{term}} \gamma_{\mathrm{td}}^{T-k} A_g^{\mathrm{out}}$$

$$\hat{A}_t = \alpha_{\mathrm{out}} A_g^{\mathrm{out}} + \alpha_{\mathrm{turn}}\, r_{\mathrm{turn}(t)}^{\mathrm{turn}}$$

TRACE 算法流程

Algorithm 1 TRACE 对一组提示词的奖励构建与策略更新。

Require: 提示词 x、标准答案 $y^\star$、当前策略 π_θ、行为快照 π_{old}、冻结参考 π_{ref}、组大小 G、时域 K、折扣 γ_{td}、偏移 ϵ、终端缩放 λ_{term}、权重 $\alpha_{\text{out}}, \alpha_{\text{turn}}$、裁剪边界 c_-, c_+

采样 G 条轨迹 $\{\tau_g\}_{g=1}^{G} \sim \pi_{\text{old}}(\cdot \mid x)$，其中 $\tau_g = (x, a_{g,1}, o_{g,1}, \ldots, a_{g,T_g}, o_{g,T_g}, \hat{y}_g)$。

计算终端奖励 $R_g = R(\hat{y}_g, y^\star)$ 和结果优势 $A_g^{\text{out}} = \text{GroupNorm}(R_g; \{R_h\}_{h=1}^{G})$，若组的标准差为 0，则对所有 g 返回 0。

for $g = 1, \ldots, G$ **do**

  从 τ_g 构建答案就绪前缀 $S_{g,0}, \ldots, S_{g,T_g}$。

  for $k = 0, \ldots, T_g$ **do**

    $$\bar{\ell}_{g,k} = \frac{1}{|y^\star|} \sum_{t=1}^{|y^\star|} \log \pi_{\text{ref}}(y_t^\star \mid S_{g,k}, y_{<t}^\star)。$$

    $$d_{g,k} = -\bar{\ell}_{g,k} + \epsilon, \qquad V_{g,k} = V(S_{g,k}) = \log \frac{d_{g,0}}{d_{g,k}}。$$

  end for

  for $k = 0, \ldots, T_g - 1$ **do**

    $$\delta_{g,k} = V_{g,k+1} - V_{g,k} = \log \frac{d_{g,k}}{d_{g,k+1}}。$$

    if $K = 0$ **then**

      令 $c_{g,k}^{(K)} = 0$ 且 $h_{g,k} = k$。

    else

      令 $h_{g,k} = \min(k + K - 1, T_g - 1)$。

      $$\text{令 } Z_{g,k} = \sum_{u=k}^{h_{g,k}} \gamma_{\text{td}}^{u-k}, \qquad c_{g,k}^{(K)} = Z_{g,k}^{-1} \sum_{u=k}^{h_{g,k}} \gamma_{\text{td}}^{u-k} \delta_{g,u}。$$

    end if

    $$r_{g,k}^{\text{turn}} = c_{g,k}^{(K)} + \mathbf{1}[h_{g,k} = T_g - 1] \lambda_{\text{term}} \gamma_{\text{td}}^{T_g - k} A_g^{\text{out}}.$$

  end for

end for

令 $\mathcal{I}_g$ 为轨迹 g 的助手 token 索引。

对于每个 g 和 $t \in \mathcal{I}_g$，设 $\hat{A}_{g,t} = \alpha_{\text{out}} A_g^{\text{out}} + \alpha_{\text{turn}} r_{g,\text{turn}(t)}^{\text{turn}}$。

$$\text{令 } \rho_{g,t}(\theta) = \frac{\pi_\theta(a_{g,t} \mid s_{g,t})}{\pi_{\text{old}}(a_{g,t} \mid s_{g,t})}。$$

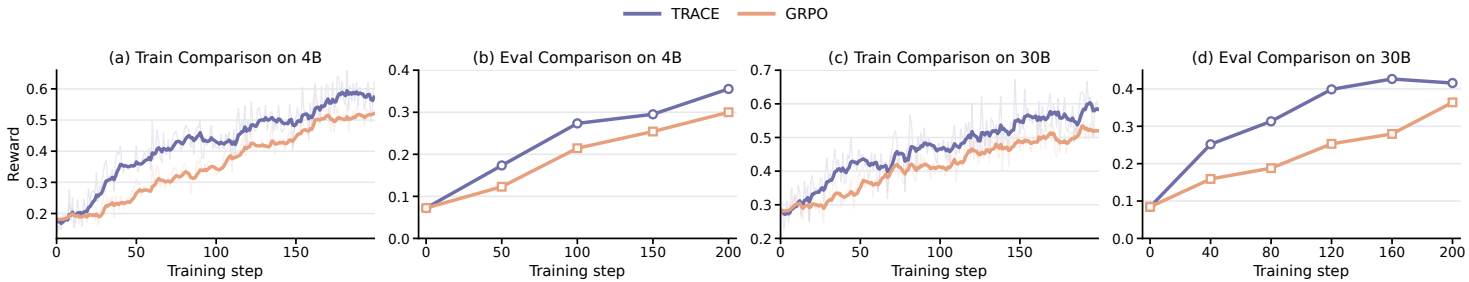
通过最大化 $\mathcal{J}_{\text{TRACE}}(\theta)$ 更新 π_θ：

$$\frac{1}{G} \sum_{g=1}^{G} \frac{1}{|\mathcal{I}_g|} \sum_{t \in \mathcal{I}_g} \min\Big(\rho_{g,t}(\theta) \hat{A}_{g,t}, \text{clip}(\rho_{g,t}(\theta), 1 - c_-, 1 + c_+) \hat{A}_{g,t}\Big)。$$

主要结果：长时程深度研究基准

模型	BC-Plus	BrowseComp	GAIA	xbench-DS	Avg
深度研究智能体（参考）					
ASearcher-QwQ-32B	28.9	5.2	52.8	42.0	32.2
WebDancer-32B	32.4	3.8	51.5	39.0	31.7
CutBill-30B-A3B	35.1	13.4	46.6	43.0	34.5
TongyiDS-30B-A3B	44.4	43.4	70.9	75.0	58.4
Qwen3-4B-Thinking					
Base	7.2	3.3	24.2	19.0	13.4
GRPO	30.0	5.1	38.8	44.0	29.5
GSPO	29.7	5.4	36.7	41.0	28.2
GiGRPO	27.7	4.4	37.9	36.0	26.5
TRACE	**35.6**	6.7	44.6	49.0	**34.0**
Qwen3-30B-A3B-Thinking					
Base	8.4	4.4	34.1	20.0	16.7
GRPO	36.4	10.8	45.6	37.0	32.5
GSPO	39.7	11.8	46.6	35.0	33.3
GiGRPO	33.0	10.1	44.7	31.0	29.7
TRACE	**42.6**	12.9	52.0	45.0	**38.1**

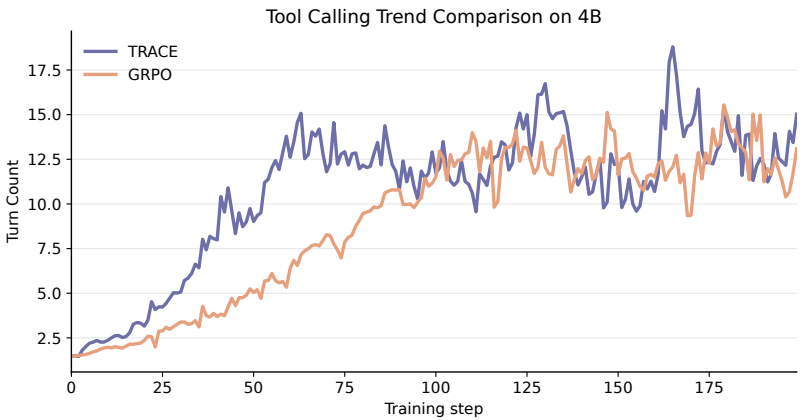
学习动态：更快收敛到更优的策略



- 四个面板（4B / 30B-A3B × 训练奖励 / 评估准确率）上，TRACE 都更早上升、斜率更陡、稳定在更高平台
- 30B-A3B 在 BC-Plus 上：160 步的 TRACE 检查点已超过 200 步的 outcome reward 基线
- 原因：outcome reward 把单个终端信号分配给整条轨迹，早期失败轨迹连同最终失误一起更新有用中间进展；TRACE 用 turn-level TD credit 减少了这种 temporal mismatch

学习动态：更早地扩大交互长度

- 左图：Qwen3-4B 在 BC-Plus 上的轨迹规模（平均 tool turns）动态——TRACE 曲线更早、更快上升，GRPO 增长缓慢
- 仅依赖最终结果的 GRPO：失败轨迹中的有效中间进展与无效交互混在一起，难以判断哪些行为值得保留
- TRACE 通过回合级信用及时奖励有助于提升最终答案质量的中间行为 ⇒ 更有效地鼓励更长且更有价值的探索



目录

3 汇报三：RLVR 更新的方向：识别与利用
- 背景与动机
- 方向性诊断：$\Delta \log p$
- 测试时外推
- 训练时优势重加权

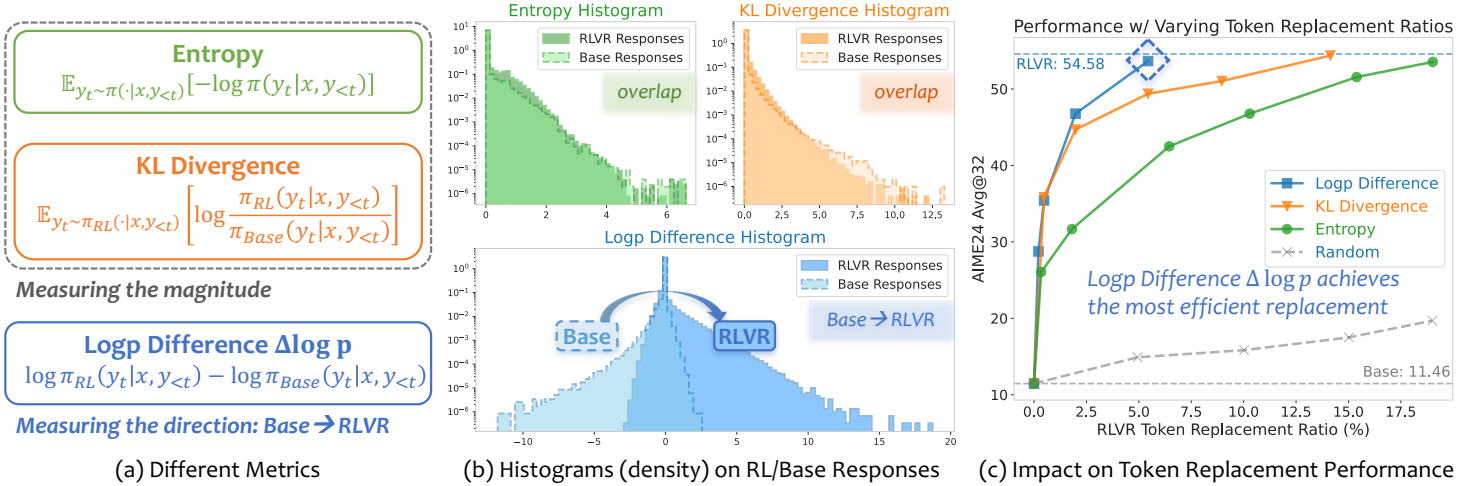
RLVR：驱动推理能力的强化学习范式

- LLM 推理能力大幅提升：OpenAI o1、DeepSeek R1、Gemini 2.5、Qwen3 等以推理为核心的模型涌现 [GYZ+25]
- 关键算法：带可验证奖励的强化学习（RLVR），利用任务验证器的反馈微调生成策略
- 理解 RLVR 收益的自然视角：比较最终 RL 模型 π_{RL} 相对其基础对应模型 π_{Base} 发生了什么变化
- 已有分析的一致结论：RLVR 引发的改变是稀疏的，只影响序列中的一小部分 token
  - 熵视角：改变集中在高熵 token [WYG+25]
  - KL 散度视角：π_{Base} 与 π_{RL} 间散度证实稀疏性 [HLZ+25]
  - 梯度视角：选择性梯度更新 [YLW+25, DCC+25]

本文指出的缺口

已有研究在分析 π_{Base} 与 π_{RL} 的差异时主要强调**变化的幅度**，而在很大程度上忽视了分布上的方向。

幅度指标无法区分 Base 与 RLVR 模型



(a) Different Metrics (b) Histograms (density) on RL/Base Responses (c) Impact on Token Replacement Performance

- (a) 用于分析 RLVR 更新的 token 级指标；(b) 各指标在 Base / RLVR 生成上的直方图
- 熵、KL 散度在两种模型输出上的分布几乎相同——只量化幅度、忽略方向
- $\Delta \log p$ 呈现清晰的双峰：正尾 = RLVR 偏好的 token，负尾 = Base 偏好的 token
- (c) token 替换实验：按 $\Delta \log p$ 选择只需最少替换即可恢复 RLVR 性能

带符号的对数概率差：捕捉更新的方向

- 直接用带符号、token 级对数概率差量化分布上的方向性偏移：

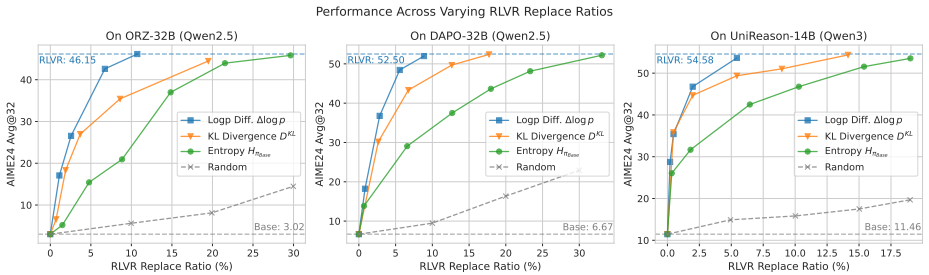
$$\Delta \log p(y_t|x, y_{<t}) = \log \pi_{\mathrm{RL}}(y_t|x, y_{<t}) - \log \pi_{\mathrm{Base}}(y_t|x, y_{<t})$$

- 正值 $\Rightarrow$ RLVR 提高了该 token 的概率（推理关键 token）；负值 $\Rightarrow$ 降低了概率（无关 token）
- 图 (b) 中 $\Delta \log p$ 的双峰分布凸显出幅度指标所不具备的方向性特征
- 与幅度指标的关键区别：熵 / KL 只度量变化大小，无法判断某个 token 更受哪个模型青睐

核心原则

诊断 RLVR 的作用应关注变化的“方向”而非仅“幅度”——对数概率差提供了一个实用抓手。

Token 替换干预：识别推理关键 token

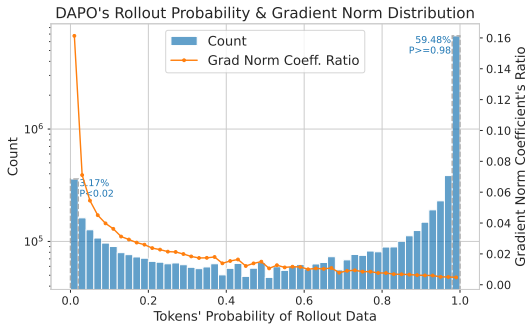


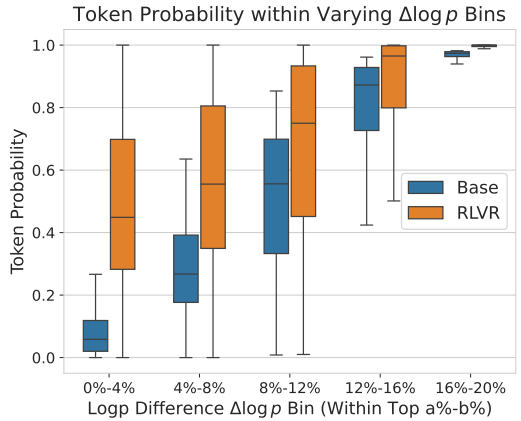
- 每个解码步：从 π_{Base} 采样，若满足指标准则 $f^{\tau}(\cdot)$ 则改用 π_{RL} 重新采样（选择性 token 替换 [MHW+26]）
- 通过阈值 τ 控制替换率，在各指标间公平比较

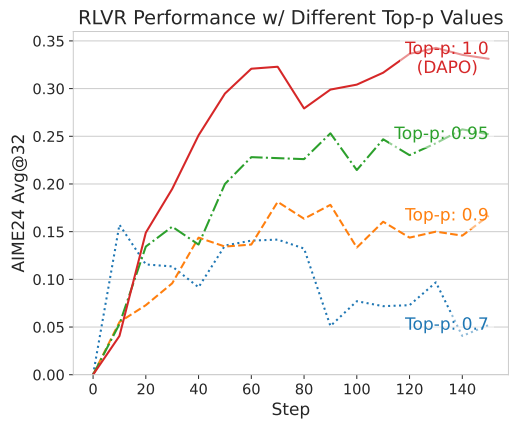
两个观察

- **观察 I**：仅替换 Base 输出中5–30%的关键 token 即可达到 RLVR 准确率；随机替换则慢得多
- **观察 II**：识别推理关键 token 的能力 $\Delta \log p >$ 散度 $>$ 熵：$\Delta \log p$ 只需约 10% 替换即可匹配 RLVR

梯度解释：稀疏更新源于低概率 token







- 引理：DAPO 目标对 logits z 的梯度 ℓ_1 范数
  $\|\nabla_z \mathcal{J}_{\mathrm{DAPO}}\|_1 = 2|w_{i,t}| \cdot \big(1 - \pi_\theta(y_{i,t})\big)$
- 概率越低，梯度越大 $\Rightarrow$ 稀有低概率 token 获得不成比例的大更新
- 高 $\Delta \log p$ 的 token 在 Base 与 RLVR 中概率都更低 $\Rightarrow$ $\Delta \log p$ 精确定位被更新的 token
- top-p 过滤实验（因果验证）：训练中过滤低概率 token（如 top-p=0.95）即使温和也显著损害性能 $\Rightarrow$ 这些 token 对推理提升不可或缺

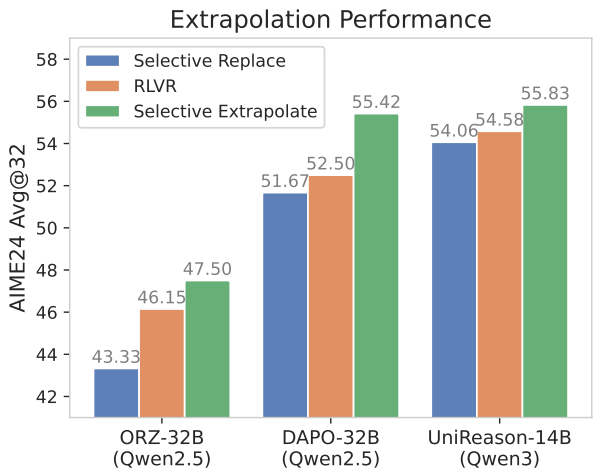
方法：沿 $\Delta \log p$ 方向选择性外推

- 将 $\Delta \log p$ 视为从 π_{Base} 指向 π_{RL} 的学到的“推理方向”，在推理时沿该方向进一步外推以放大信号：

$$\log \pi^{\gamma}_{\text{Extra}}(y_t|x, y_{<t}) = \log \pi_{\text{RL}}(\cdot) + \gamma \cdot \Delta \log p(\cdot) + z = (1+\gamma) \log \pi_{\text{RL}}(\cdot) - \gamma \log \pi_{\text{Base}}(\cdot) + z$$

- 概率空间等价形式：
$\pi^{\gamma}_{\text{Extra}}(y_t) \propto \pi_{\text{RL}}(y_t) \cdot \exp\left(\gamma\ \Delta \log p(y_t)\right)$
- 为什么选择性：RLVR 改进集中在少数 token，多数位置 $\Delta \log p \approx 0$，全局干预会扭曲校准良好的 token
- 实现：沿用替换框架，仅当 f^{τ}_{logp} 判定 $\Delta \log p$ 为较大负值时，从外推分布 $\pi^{\gamma}_{\text{Extra}}$ 采样

实验结果与理论依据



- 匹配筛选下，选择性外推在 ORZ-32B / DAPO-32B / UniReason-14B 上均超过 π_{RL}（Avg@32, AIME-24）
- 选择性替换只能匹配、无法超越 RL 基线

直接在 π_{RL} 上外推 (DAPO-32B, $\gamma = 0.1$)

替换比率	0.0%	1.8%	5.2%	20.0%
Avg@32	52.50	53.96	**55.31**	55.10
阈值 τ	–	-0.5	-0.2	0.0

理论依据（简化设定）

表格型 softmax + 自然策略梯度 (NPG)：外推策略 $\pi_{\omega(\theta^t,\gamma)}$，$\omega = \theta^t + \gamma(\theta^t - \theta^0)$，则 $\exists \gamma > 0$ 使期望奖励 $\mathbb{E}_{y\sim\pi_\omega}[R] \geq \mathbb{E}_{y\sim\pi_{\theta^t}}[R]$（奖励为常数时取等号）。

方法：概率感知的优势重加权

- 测试时：沿 $\Delta \log p$ 选择性外推，放大 RL 已学到的方向
- 训练时：进一步利用 低概率 token 的重要性，主动放大其学习信号

$$\tilde{A}_{i,t} = \underbrace{\left[1 + \alpha\left(1 - \pi_{\text{old}}(y_{i,t} \mid x, y_{i,<t})\right)\right]}_{\text{低概率} \Rightarrow \text{更大权重}} \hat{A}_{i,t}$$

- 低概率 token：$\pi_{\text{old}}(y_{i,t}) \downarrow \Rightarrow$ advantage 权重 $\uparrow$
- 高概率 token：权重接近 1，基本保持原有 DAPO 更新
- 只修改 advantage，其余 DAPO 配置保持不变

核心直觉

RLVR 真正重要的更新集中在少数低概率 token，因此训练时应该让这些 token “说话更有分量”。

主结果：跨模型、跨数据集一致提升

模型	方法	AIME24		AIME25		AMC		平均	
		Avg@32	Pass@16	Avg@32	Pass@16	Avg@32	Pass@16	Avg@32	Pass@16
Qwen2.5-Math-7B	Base	14.79	47.46	6.67	27.84	40.62	79.25	20.69	51.52
	DAPO	35.73	54.09	17.60	30.45	73.04	89.03	42.12	57.86
	本文	**39.06**	**60.58**	**18.54**	**36.72**	**73.64**	**89.69**	**43.75**	**62.33**
Qwen3-8B-Base	Base	5.42	30.63	5.73	32.80	27.64	78.09	12.93	47.17
	DAPO	36.98	**72.30**	26.67	46.76	69.13	88.51	44.26	69.19
	本文	**38.13**	69.87	**31.15**	**55.38**	**71.05**	**92.30**	**46.78**	**72.52**

提升的 Avg@32 并非以牺牲探索（Pass@k）为代价；平均 Pass@16 也比 DAPO 基线提升。

参考文献 I

[DA+25] DeepSeek-AI et al.
Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning, 2025.

[DCC+25] Jia Deng, Jie Chen, Zhipeng Chen, Wayne Xin Zhao, and Ji-Rong Wen.
Decomposing the entropy-performance exchange: The missing keys to unlocking effective reinforcement learning, 2025.

[GYZ+25] Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Peiyi Wang, Qihao Zhu, et al.
Deepseek-r1 incentivizes reasoning in llms through reinforcement learning.
Nature, 645:633–638, 2025.

[HLZ+25] Maggie Huan, Yuetai Li, Tuney Zheng, Xiaoyu Xu, Seungone Kim, Minxin Du, Radha Poovendran, Graham Neubig, and Xiang Yue.
Does math reasoning improve general llm capabilities? understanding transferability of llm reasoning.
arXiv preprint arXiv:2507.00432, 2025.

[HMW+26] Kexin Huang, Haoming Meng, Junkang Wu, Jinda Lu, Chiyu Ma, Ziqian Chen, Xue Wang, Bolin Ding, Jiancan Wu, Xiang Wang, Xiangnan He, Guoyin Wang, and Jingren Zhou.
On the direction of rlvr updates for llm reasoning: Identification and exploitation, 2026.

[KPR+17] James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, et al.
Overcoming catastrophic forgetting in neural networks.
Proceedings of the national academy of sciences, 114(13):3521–3526, 2017.

[MHW+26] Haoming Meng, Kexin Huang, Shaohang Wei, Chiyu Ma, Shuo Yang, Xue Wang, Guoyin Wang, Bolin Ding, and Jingren Zhou.
Sparse but critical: A token-level analysis of distributional shifts in RLVR fine-tuning of LLMs.
In *The Fourteenth International Conference on Learning Representations*, 2026.

参考文献 II

[NHB+21] Reiichiro Nakano, Jacob Hilton, Suchir Balaji, et al.
Webgpt: Browser-assisted question-answering with human feedback, 2021.

[RGB11] Stéphane Ross, Geoffrey Gordon, and Drew Bagnell.
A reduction of imitation learning and structured prediction to no-regret online learning.
pages 627–635, 2011.

[SWZ+24] Zhihong Shao, Peiyi Wang, Qihao Zhu, et al.
Deepseekmath: Pushing the limits of mathematical reasoning in open language models.
In *Conference on Language Modeling (COLM)*, 2024.

[TPY+26] Leitian Tao, Baolin Peng, Wenlin Yao, Tao Ge, Hao Cheng, Mike Hang Wang, Jianfeng Gao, and Sharon Li.
TRACE: Turn-level reward assignment via credit estimation for long-horizon agents, 2026.

[WYG+25] Shenzhi Wang, Le Yu, Chang Gao, Chujie Zheng, Shixuan Liu, Rui Lu, Kai Dang, Xionghui Chen, Jianxin Yang, Zhenru Zhang, et al.
Beyond the 80/20 rule: High-entropy minority tokens drive effective reinforcement learning for llm reasoning.
arXiv preprint arXiv:2506.01939, 2025.

[YLW+25] Zhihe Yang, Xufang Luo, Zilong Wang, Dongqi Han, Zhiyuan He, Dongsheng Li, and Yunjian Xu.
Do not let low-probability tokens over-dominate in rl for llms.
arXiv preprint arXiv:2505.12929, 2025.

[YZY+23] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao.
React: Synergizing reasoning and acting in language models.
In *International Conference on Learning Representations (ICLR)*, 2023.

Thanks!

附录：Proof of Lemma 3.1

Proof of Lemma 3.1. For ease of notation, we omit the context $x, y_{i,<t}$ here. The derivative of DAPO on an unclipped token $y_{i,t}$ is:

$$\begin{aligned}\nabla_\theta \mathcal{J}_{\text{DAPO}}(y_{i,y}) = \nabla_\theta\, r_{i,t}(\theta)\hat{A}_{i,t} &= \nabla_\theta \frac{\pi_\theta(y_{i,t})}{\pi_{\theta_{\text{old}}}(y_{i,t})}\hat{A}_{i,t} \\ &= r_{i,t}(\theta)\hat{A}_{i,t}\cdot\nabla_\theta \log \pi_\theta(y_{i,t}) \\ &= w_{i,t}\cdot\nabla_\theta \log \pi_\theta(y_{i,t}).\end{aligned}$$

For the softmax-parameterized policy π_θ with logits z for $y_{i,t}$, assuming $y_{i,t}$ corresponds to index k of vocabulary $\mathcal{V}$, we have:

$$\begin{aligned}\frac{\partial}{\partial z_j}\log \pi_\theta(y_{i,t}) &= \frac{1}{\pi_\theta(y_{i,t})}\cdot\frac{\partial}{\partial z_j}\frac{\exp(z_k)}{\sum_l \exp(z_l)} \\ &= \frac{1}{\pi_\theta(y_{i,t})}\cdot\begin{cases}\frac{\exp(z_k)\sum_l \exp(z_l)-\exp(z_k)\exp(z_k)}{(\sum_l \exp(z_l))^2}, & j=k \\ \frac{-\exp(z_k)\exp(z_j)}{(\sum_l \exp(z_l))^2}, & j\neq k\end{cases} \\ &= \begin{cases}1-\pi_\theta(\mathcal{V}_k), & j=k \\ -\pi_\theta(\mathcal{V}_j), & j\neq k\end{cases} \\ &= \mathbb{I}(j=k)-\pi_\theta(\mathcal{V}_j).\end{aligned}$$

So the $\ell 1$-norm of $\nabla_z \mathcal{J}_{\text{DAPO}}(y_{i,t})$ becomes:

$$\begin{aligned}\|\nabla_z \mathcal{J}_{\text{DAPO}}(y_{i,t})\|_1 &= \|w_{i,t}\nabla_z \log \pi_\theta(y_{i,t})\|_1 \\ &= |w_{i,t}|\cdot\sum_j\left|\mathbb{I}(j=k)-\pi_\theta(\mathcal{V}_j)\right| \\ &= |w_{i,t}|\cdot\Big(1-\pi_\theta(y_{i,t})+\sum_{j\neq k}\pi_\theta(\mathcal{V}_j)\Big) \quad (y_{i,t}=\mathcal{V}_k) \\ &= |w_{i,t}|\cdot 2\big(1-\pi_\theta(y_{i,t})\big).\end{aligned}$$